

### Članek:

Automatic Recognition of Motor Skills in Triathlon: A Novel Tool for Measuring Movement cadence and Cycling Tasks

### Avtorji:

Stuart M. Chesher, Carlo Martinotti, Dale W. Chapman, Simon M. Rosalie, Paula C. Charlton, Kevin J. Netto

### Revija:

Journal of Functional Morphology and Kinesiology,

2024, 9(4), 269; <https://doi.org/10.3390/jfmk9040269>

### **Namen študije:**

Izdelava in validacija algoritma za detekcijo vrhov za merjenje kadence gibanja pri triatlonu (plavanje, kolesarjenje, tek) in modela strojnega učenja za prepoznavanje gibalnih vzorcev (kolesarjenje sede, kolesarjenje stoje in kolesarjenje brez poganjanja pedal) pri kolesarjenju.

### **Osnovne hipoteze oziroma raziskovalna vprašanja:**

Ali sta izdelan algoritem in model strojnega učenja učinkovita orodja za avtomatično analizo športne uspešnosti v triatlonu?

### **Uporabljene statistične metode:**

- Izvedena je bila eksperimentalna in validacijska študija.
- V študiji je sodelovalo 12 triatloncev. V prvem delu študije je sodelovalo 6 tekmovalcev v mlajših kategorijah. Po pregledu podatkov so avtorji ugotovili, da imajo za učenje klasifikacijskega modela neenakomerno količino podatkov gibalnih vzorcev pri kolesarjenju, zato so namensko rekrutirali še 6 triatloncev. Testni protokoli prvih 6 (skupina A) in drugih 6 merjencev (skupina B) so se razlikovali.
- Skupina A: 10-minutno ogrevanje, kateremu sledi opravljanje po meri narejenega poligona (400m plavanja, 20km kolesarjenja in 5km teka). Udeleženci so štartali v 30-sekundnih intervalih in opravili s poligonom.
- Skupina B: Po poligonu so kolesarili in vsakih 20 sekund zamenjali gibalni vzorec. Tako so pridobili še 217 minut podatkov za učenje modela strojnega učenja.
- Zajem podatkov: v posebej narejenem žepku, na hrbtni strani triatlonskega dresa so imeli spravljeno mersko enoto (Optimeye S5). Merska enota vsebuje 3-osni pospeškomer, žiroskop in GPS senzor. Po progi so bile postavljene tudi statične kamere, udeleženci pa so na kolesu imeli montirane mobilne kamere. Za sinhronizacijo merilne opreme so udeleženci pred začetkom vsake discipline petkrat vidno udarili po IMU senzorju.
- Validacijski podatki so bili iz video posnetkov ročno prešteti zaveslaji roke pri plavanju, vrtljaji pedala pri kolesarjenju in koraki pri teku. V članku definirajo posamezen zaveslaj, vrtljaj in korak. Prav tako definirajo gibalne vzorce.
- Za razvoj algoritma detekcije vrhov so uporabili podatke pospeškometra, ki so jih filtrirali in določili minimalni interval med dvema vrhovoma. Parametri so bili različni za različne panoge triatlona.
- Za razvoj klasifikacijskega modela strojnega učenja so uporabili podatke pospeškometra in žiroskopa. Podatke so predprocesirali enako kot za detekcijo vrhov, nato pa so jih z

uporabo Fourierjeve transformacije s kratkim časovnim oknom (short-time Fourier transform). Uporabili so XGBClassifier, ki so ga trenirali s programsko opremo XGBoost. Za učenje modela so uporabili 3 naključno izbrane udeležence iz skupine A in 3 naključno izbrane iz skupine B. Podatke so razdelili na 80% - učni podatki, 20% - testni podatki. Ostalih 6 udeležencev so uporabili za generalizacijo modela.

- Za validacijo algoritma za detekcijo vrhov so uporabili ročno prešteto kadenco iz video posnetkov kamer.
- Rezultate so predstavili v tabeli 1 kot natančnost v odstotkih in kot koren srednje kvadratne napake (RMSE) za posameznega udeleženca. V zadnji vrstici so rezultat predstavili tudi kot povprečje in standardni odklon skupine A.
- Rezultati modela strojnega učenja so predstavljeni v tabeli 2. Ker model ni dobro ločeval kolesarjenja brez poganjanja od kolesarjenja sede, so v tabeli 2 prikazali samo natančnost med klasifikacijo kolesarjenja stoje/sede. Rezultati so predstavljeni kot odstotek natančnosti, specifičnosti in senzitivnosti.
- Model strojnega učenja je poleg klasifikacije z uporabo GPS podatkov in podatkov o kadenci na zemljevid vrisal tudi športno uspešnost, kar je predstavljeno na sliki 2.
- Algoritem in strojno učenje so avtorji razvili v programskem okolju Python z uporabo knjižnice ScyPy. *Avtorji niso zapisali katero orodje so uporabili za statistično obdelavo podatkov, vendar lahko sklepamo, da je to bil Python.*

#### Statistična analiza:

- Izračunali so opisno statistiko za posameznega udeleženca (povprečje kadence  $\pm$  standardni odklon).
- Vrednotenje kadence so avtorji prikazali z odstotkom pravilno označenih vrhov pri zaveslajih, obratih in korakih ter pravilno klasificiranih gibalnih vzorcev.
- Vrednotenje napake algoritma za označevanje vrhov so predstavili s korenem srednje kvadratne napake in relativno napako. Za vrednotenje napake modela so izračunali specifičnost in občutljivost. *Mogoče bi bilo dobro rezultate vrednotenja primerjati z rezultati trenutno najboljše opreme za merjenje kadence, vsaj iz vidika, koliko bolje/slabše deluje razvit algoritem (za kadenco teka primerjava z Garmin Running Dynamics Pod, za kadenco kolesarjenja primerjava z Garmin Cadence Sensor 2, za kadenco plavanja MySwimEdge).*

#### Pravilnost zaključkov glede na rezultate statistične analize:

- Zaključek 1:
- In swimming, comparing the RMSE with the sample standard deviation shows that the expected error range is 0.33 standard deviations from the mean, giving an expected range of 74.3 to 79.7 strokes/min for an elite open-water swimmer with a medium cadence (77 strokes/min) [25]. This indicates a high degree of accuracy. In cycling, comparing the RMSE with the sample standard deviation shows that the expected error range is  $\pm 1.38$  standard deviations from the mean. For an elite triathlete cycling at an average cadence (194 pedals/min or 97 RPM), the expected range is 185 to 203 pedals/min (or 92.5 to 101.5 RPM). Thus, the accuracy is lower than in swimming, but the error range remains practically useful. Finally, in running, comparing the RMSE with the sample standard deviation shows that the expected error range is  $\pm 0.2$  standard deviations from the mean, giving an expected range of 180.8 to 183.2 strides/min for an elite triathlete with a cadence of 182 strides/min [26] which is considered highly accurate.

Trditve so potrjene s podatki v prvem delu dela z rezultati. V nadaljevanju je tudi komentar, ki obrazloži, da je natančnost avtomatiziranega procesa nekoliko nižja kot pri sistematičnem pregledu literature izvedenem pred to raziskavo. *Avtorji bi lahko bolj očitno zapisali zaključek v smislu – avtomatska detekcija kadence deluje zadovoljivo.*

- Zaključek 2:

**The machine learning model developed to detect transitions between cycling tasks successfully differentiated between ‘in-saddle’ and ‘out-of-saddle’ riding but was inaccurate at distinguishing between ‘in-saddle’ riding and ‘coasting’ [...] the model still failed to distinguish ‘coasting’ from ‘in-saddle’ riding, likely due to the small amplitude differences between the two tasks, compounded by the sensor’s torso placement, which attenuates reaction forces through the kinetic chain—a finding echoed in running studies**

Trditev je podkrepljena z obrazložitvijo nizke občutljivosti in visoke specifičnosti modela. V nadaljevanju avtorji obrazložijo omejitve študije. Prišlo je do precejšnjih razlik pri specifičnosti med skupinama. Specifičnost je bila previsoko ocenjena zaradi prevelike zastopanosti določenih gibalnih vzorcev; vožnja sede je bila pri skupini A zastopana približno 90-94%. Avtorji opozorijo, da model ni bil zmožen razlikovati med vožnjo sede in vožnjo sede, brez vrtenja pedalov, kar podkrepijo z razlago (majhne razlike v amplitudah pospeškov, oddaljenost IMU od nog zmanjšuje možnost pridobivanja kinematičnih podatkov spodnjih okončin). Predlagajo nadgradnjo z uporabo konvolucijskega nevronskega omrežja in s skrajšanjem časovnih oken pri uporabi Fourierjeve transformacije.

- Zaključek 3:

**Developing a peak-counting algorithm to measure cadence at customisable intervals, along with a machine learning model to recognise cycling task changes, is an important step towards improving motor skill analysis and the practise design in triathlon.**

Avtorji celoten članek pišejo s to trditvijo v mislih. V uvodu postavijo temelje, zakaj je razvoj take tehnologije pomemben, nato pa v diskusiji poleg rezultatov predstavijo možne implikacije tehnologije.

Prav tako izpostavijo omejitve:

- študija je zastavljena le kot prikaz delovanja tehnologije, zato algoritmi še niso optimizirani,
- premajhen vzorec,
- postavitev IMU senzorja ni bila optimalna za detekcijo kinematike spodnjih okončin. *Senzor bi lahko postavili na križ; tako bi verjetno povečali občutljivost modela, hkrati pa ne bi izgubili preveč pri natančnosti ocene kadence zaveslajev.*

### Članek:

A Comparison of Stride Length and Lower Extremity Kinematics during Barefoot and Shod Running in Well Trained Distance Runners

### Avtorji:

Peter Francis, James Ledingham, Sarah Clarke, DJ Collins, Philip Jakeman

### Revija:

Journal of Sports Science and Medicine, 2016 Aug 5;15(3):417–423.

PMCID: PMC4974854

### **Namen študije:**

V članku je izvedena študija vpliva tipa obutve in hitrosti teka na dolžino koraka in kinematiko nog dobro treniranih tekačev na dolge proge.

### **Osnovne hipoteze oziroma raziskovalna vprašanja:**

1. Prva hipoteza: Bosonog tek vpliva na skrajšanje koraka glede na tek v tekaških čevljih.

### *Dodatna analiza:*

### **Uporabljene statistične metode:**

- Izvedena je bila eksperimentalna študija s ponovljivimi meritvami.
- V študiji je sodelovalo 9 dobro treniranih tekačev na srednje dolžine, ki so ogrevanje in ohlajanje pogosto izvajali bosi. Lastnosti skupine so opisane. *Skupina tekačev je homogena glede tedensko pretečene kilometrine (100 km/teden  $\pm$  16km/teden) in časa na 1500m (3 min 59.8 sec  $\pm$  14.7 sec).*
- Določitev velikosti vzorca je bila podrejena homogenosti vzorca in praktičnosti. Izbrali so tekače Univerzitetnega atletskega kluba univerze Limerick, ki tekmujejo na državnem univerzitetnem nivoju v tekih na srednje proge (800 – 5000m). *Lahko je težava v prevodu, vendar »distance runners« v slovenščino prevedemo kot »tek na dolge proge«, v študiji pa so sodelovali tekači na srednje proge.*
- Udeleženci so opravili testni protokol na tekalni stezi:
  - o 5 minut ogrevanja pri lastno izbrani hitrosti,
  - o Naključno določen prvi pogoj (bos/obut),
  - o 2 minuti počasnega teka (3.05 m/s), 2 minuti pavze in 2 minuti hitrega teka (4.72 m/s).
  - o 2 minuti stacionarne pavze, med katero so se preobuli,
  - o Ponovljena meritev pod drugim pogojem (obut/bos).
- Vsi udeleženci so tekli v enakih čevljih (New Balance MR350WR), bili oblečeni v pajkice in oprijeto majico. Na levo nogo so imeli nameščenih 11 odbojnih markerjev.
- Zajem podatkov je potekal s pomočjo štirih kamer (3D Eagle infrared motion Analysis Corporation), ki so bile dnevno kalibrirane. Zajem se je začel 60 sekund v posameznem pogoju in je trajal 20 sekund.
- Za preverjanje normalnosti porazdelitve so uporabili Shapiro-Wilk test normalnosti.
- Testiranje statistično značilnih razlik med spremenljivkama je bilo izvedeno s 2x2 faktorsko ANOVO. *Lahko bi uporabili tudi ANOVO s ponovljivimi meritvami.*

- Podatki rezultatov so podani v tabeli 1 kot povprečje (standardni odklon), interval min-max za posamezni pogoj in kot razlika med pogojem, s p-vrednostji in velikostjo efekta (Cohen's d).
- Za statistično analizo so uporabljali program SPSS.

#### Statistična analiza:

- Opisna statistika za dolžino koraka in kote kolka, kolena in gležnja je prikazana v tabeli 1. Podatki so podani kot povprečje (standardni odklon), interval najmanjše in največje vrednosti. *Nikjer v članku ni opisano kateri kot je opredeljen kot povprečje. Koti v sklepih se pri teku navadno gledajo po fazah koraka (ob stiku s tlemi, ob odmiku noge od tal; »toe-off«, na sredi faze zamaha), kot tudi interval maksimalnega in minimalnega kota; »range of motion«. Glede na številke lahko sklepamo, da so uporabili povprečje povprečnega kota sklepa vseh tekačev.*
- V tabeli 1 so podani tudi rezultati 2x2 faktorske analize razlike med obutim in bosim tekom (povprečna razlika (standardni odklon), p-vrednost, velikost efekta).
- Glavni rezultati analize, torej rezultati 2x2 faktorske analize so podani v besedilu (vrednost F-testa in p-vrednost) iz katerih lahko razberemo, da ima hitrost teka vpliv na dolžino koraka in kota v kolku, obutev vpliva na kot v kolku, interakcija med hitrostjo teka in obutvijo pa statistično značilno vplivata na kot v kolenu in gležnju. *Glavni rezultati bi morali biti podani tudi v tabeli. Verjetno se avtorji za to niso odločili, ker bi se rezultati preveč ponavljali.*
- Ker so avtorji ugotovili, da obutev ni imela vpliva na skrajšanje koraka so s stolpčnima grafoma (1 in 2) prikazali še relativne razlike dolžine koraka in kotov v sklepih nog glede na obutev. Iz grafa je razvidna precejšnja razpršenost rezultatov. *Avtorji v diskusiji argumentirajo zakaj bi lahko do takšne razpršenosti prišlo. Tekачi, ki so sodelovali v študiji so bili specializirani za različne dolžine teka, kar se lahko odraža pri tem, da je bil pogoj hitrega teka za nekatere tekače še vedno počasen. V tem primeru bi bilo smotno povečati število tekačev.*

#### Pravilnost zaključkov glede na rezultate statistične analize:

- Zaključek 1:  
**Speed had a significant main effect on stride length and hip angles ( $p < 0.05$ ). Footwear had a significant main effect on hip angle ( $p < 0.05$ ). The interaction between speed and footwear had a significant effect on knee and ankle angles ( $p < 0.05$ ).**

Trditve so podprte z rezultati F-testov 2x2 faktorske ANOVE predstavljene v odlomku z rezultati. Avtorji temu v zaključku ne posvečajo preveč besed. *Lahko bi napisali, ali se rezultati skladajo z literaturo.*

- Zaključek 2:  
**Compared to shod running, barefoot running ( $3.0 - 3.3 \text{ m} \cdot \text{s}^{-1}$ ) leads to a reduction in stride length (6 – 8%) in inexperienced and those with a long history of barefoot running (Diver et al., 2005; Squadrone and Gallozzi, 2009; Thompson et al., 2014). We did not find a significant main effect of footwear on stride length in our study ( $p = 0.060$ ).**

Večini tekačev (7 od 9) se je pri nižji hitrosti dolžina koraka zmanjšala, vendar ne toliko kot v prejšnjih študijah. En razlog pripisujejo različni populaciji tekačev uporabljeni pri tej študiji. Dobro trenirani tekači na splošno tečejo s krajšimi koraki kot neizkušeni tekači. Pri

večji hitrosti se je pokazala zelo heterogena razlika med obutim in bosonogim tekom. Avtorji to pripisujejo razlikam v glavni disciplini tekačev (800m je 4.72 m/s še vedno počasi) in majhnemu vzorcu.

- Zaključek 3:

**The present investigation reports a main effect of speed ( $p = 0.029$ ) and footwear ( $p = 0.050$ ) on hip angle and a speed\*footwear interaction for knee angle ( $p = 0.027$ ). [...] At the ankle joint, there was a significant speed\*footwear interaction ( $p = 0.030$ ).**

Rezultati so predstavljeni v tabeli 1 in v delu besedila z rezultati. *Lahko bi bili predstavljeni v ločeni tabeli.* Kot v kolku in kolenu se je pri nižji hitrosti bolj homogeno povečeval, kot pri višji hitrosti, predvsem zaradi različnih učinkovitosti tekačev (tekači na 800m so bolj učinkoviti pri višjih hitrostih). Kot v gležnju se je gledano na povprečje povečal glede na interakcijo med obutvijo in hitrostjo, med posamezniki pa je bilo videti kar nekaj razlik. Avtorji so to poudarili s stolpčnima grafoma. Razlike avtorji pripisujejo različnim navadam pri udarcu z nogo ob tla (udarec na peto, na sredino stopala ali na prste različno vpliva na kinematiko gležnja).

- Končna ugotovitev:

**We report speed to have a significant main effect on stride length and hip angles in well trained runners with previous exposure to barefoot running. Furthermore, we report footwear to have a significant main effect on hip angle and a significant speed\*footwear interaction to occur for knee and ankle angles.**

To je povzetek prvega zaključka, ki predstavlja bistvo te študije.